DSP391m · Bảo vệ cuối kỳ · FPT University · Fall 2026

Dự báo lưu lượng và mức nguy cơ lũ sông Hương tại Kim Long, 1–3 ngày tới

Một lớp hiệu chỉnh cục bộ trên GloFAS — dữ liệu mở, ~107.5 triệu bản ghi giờ, chạy tự động mỗi sáng

Đặng Nguyên Giáp
Tech Lead
Bài toán · dữ liệu · Spark · hệ thống vận hành

Hồ Anh Đức
Data Analyst
Mô hình · đánh giá · cảnh báo · SHAP

Mai Thị Lệ Huyền
Research & Docs
DL · thử giảm cắt ngọn · hạn chế · kết luận

Huế có vài giờ, không phải vài ngày

5.05 m

mực nước Kim Long ngày 27/10/2025 — cao hơn báo động III 1.55 m (theo tin báo)

5–6 giờ

để mưa trên núi về tới Huế: lưu vực ngắn và dốc

1–3 ngày

báo trước là thời gian để dân kê đồ, neo thuyền, sơ tán

CÂU HỎI CỦA ĐỒ ÁN

Lưu lượng tại Kim Long 1, 2, 3 ngày tới là bao nhiêu — và có vượt mức nguy cơ không?

Định vị: lớp hiệu chỉnh cục bộ trên GloFAS

GloFAS v4 (Copernicus)

- Mô phỏng thuỷ văn toàn cầu, ô ~5 km, theo ngày, miễn phí
- Không mô phỏng hồ Tả Trạch, Bình Điền
- Thiếu lũ lớn: nước vào hồ > GloFAS ở 14/23 ngày kiểm

→

Lớp hiệu chỉnh cục bộ

- LightGBM cấu hình E, 88 đặc trưng
- Học lưu lượng GloFAS 1–3 ngày tới từ mưa giờ, hệ thống thời tiết, trạng thái lưu vực
- Thêm thông tin cục bộ mà GloFAS không dùng lúc phát báo

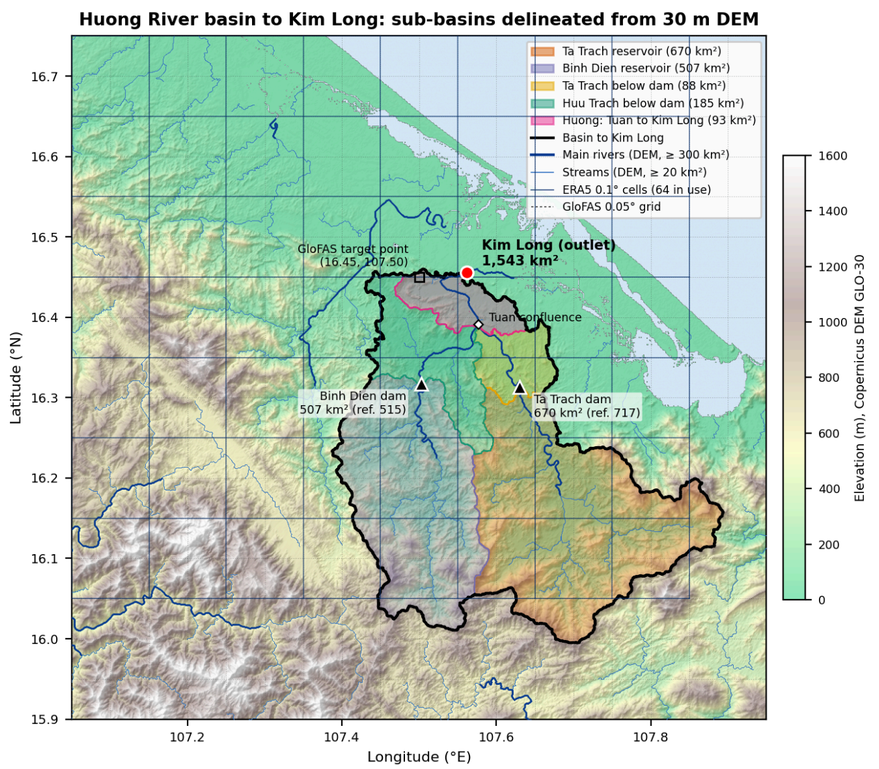
→

Đầu ra mỗi sáng

- Lưu lượng 1–3 ngày tới (m^3/s)
- Mức nguy cơ 806 / 1,275 / 1,905 m^3/s
- Xác suất vượt mức 1 đã hiệu chỉnh, báo khi ≥ 1/11

Không thay GloFAS. Không có số đo KTTV ⇒ mục tiêu là **lưu lượng GloFAS v4 theo ngày** tại ô (16.45 N, 107.50 E). Mức nguy cơ là phân vị mùa lũ, **không phải BĐ I/II/III**.

Lưu vực sông Hương tới Kim Long



1,543 km²

lưu vực tới Kim Long, cắt từ DEM 30 m — đính chính con số 2,830 km² cũ (gồm cả sông Bồ 938 km²)

5 lưu vực con

Tả Trạch 670 · Bình Điền 507 · dưới đập 88 + 185 · Tuần–Kim Long 93 km²

646 + 424 triệu m³

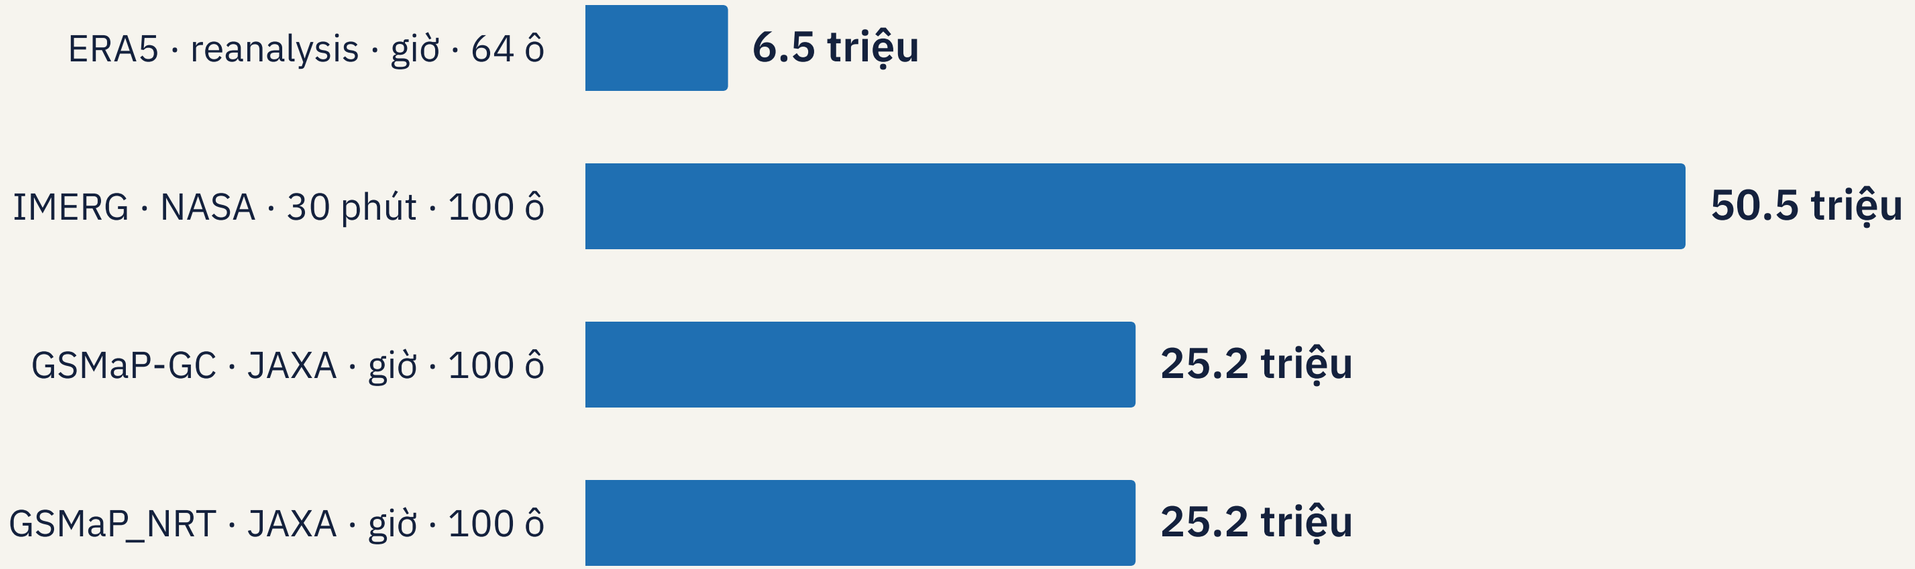
dung tích hồ Tả Trạch và Bình Điền — GloFAS không mô phỏng hai hồ này

6,087 ngày

EDA: Q trung vị 49.7, cực đại 3,588 m³/s (08/11/2011); tháng 9–12 = 58.6 % dòng chảy năm

Đặng Nguyên Giáp

Dữ liệu: mưa theo giờ từ bốn nguồn mở



Tổng ≈ 107.5 triệu bản ghi giờ · 1998–2026 · Parquet chia theo nguồn / năm / tháng

Thêm: ERA5-Land (độ ẩm đất) · IBTrACS 417 cơn bão · không khí lạnh · ENSO (ONI trễ 3 tháng) · tin xả hồ

Một pipeline, từ tải dữ liệu tới bản tin mỗi sáng

1

Thu thập

Tác vụ độc lập, bỏ qua file đã có, khoá chống chạy song song

→

2

Lưu trữ

Parquet theo nguồn / năm / tháng, giờ Việt Nam

→

3

Xử lý

Giờ → ngày → 5 lưu vực con; 54 đặc trưng mưa giờ (Polars; cùng logic trên Spark)

→

4

Học & đánh giá

LightGBM E, walk-forward 13 năm, bootstrap + Wilcoxon

→

5

Vận hành

Job 05:00 mỗi sáng → nhật ký CSV → dashboard

Mỗi bước tự kiểm được: tổng nhãn 00–23 h trùng mưa ngày (lệch ≤ 1.7e-13 mm, dời ±1 h lệch 27.5–47.5 mm) · cắt dữ liệu ở 3 mốc rồi tính lại: ngày trước mốc không đổi · Spark = Polars từng bit.

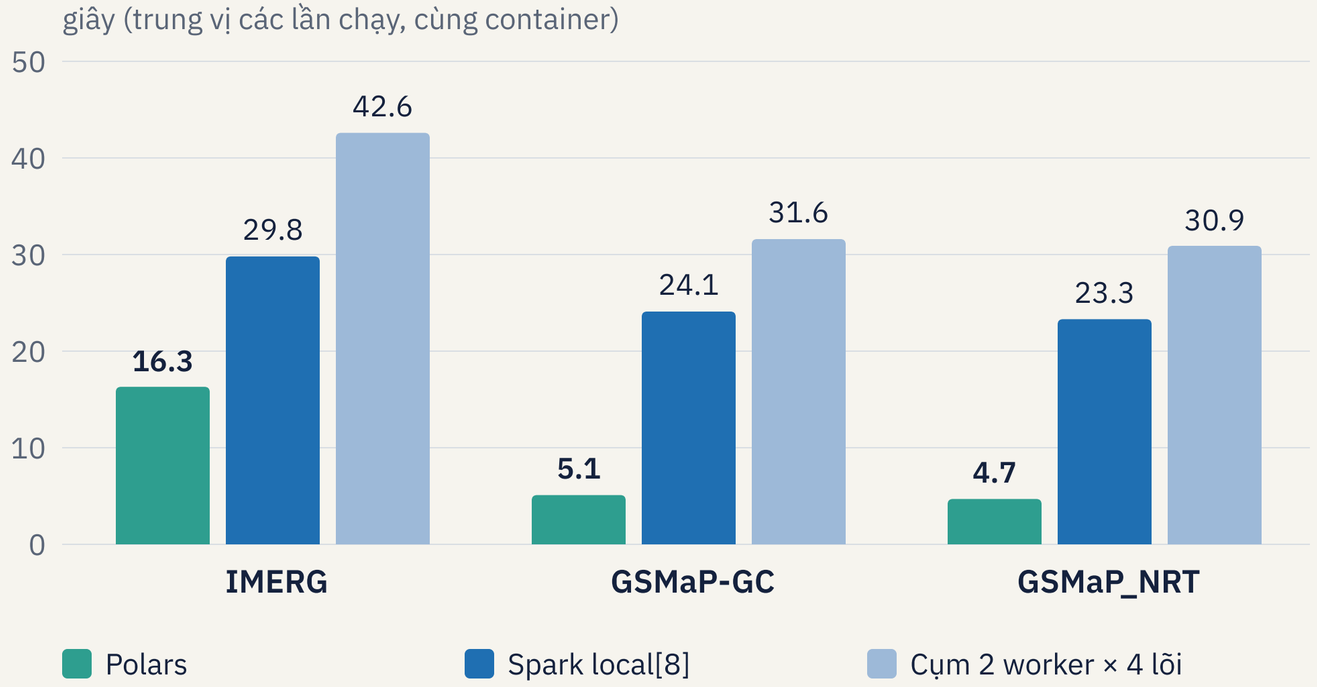
Spark ở quy mô đủ: toàn bộ lưu trữ vệ tinh

101.0 triệu

dòng giờ vệ tinh (IMERG + GSMaP-GC + GSMaP_NRT, 125 MB) xử lý trên cụm Spark

0 khác biệt

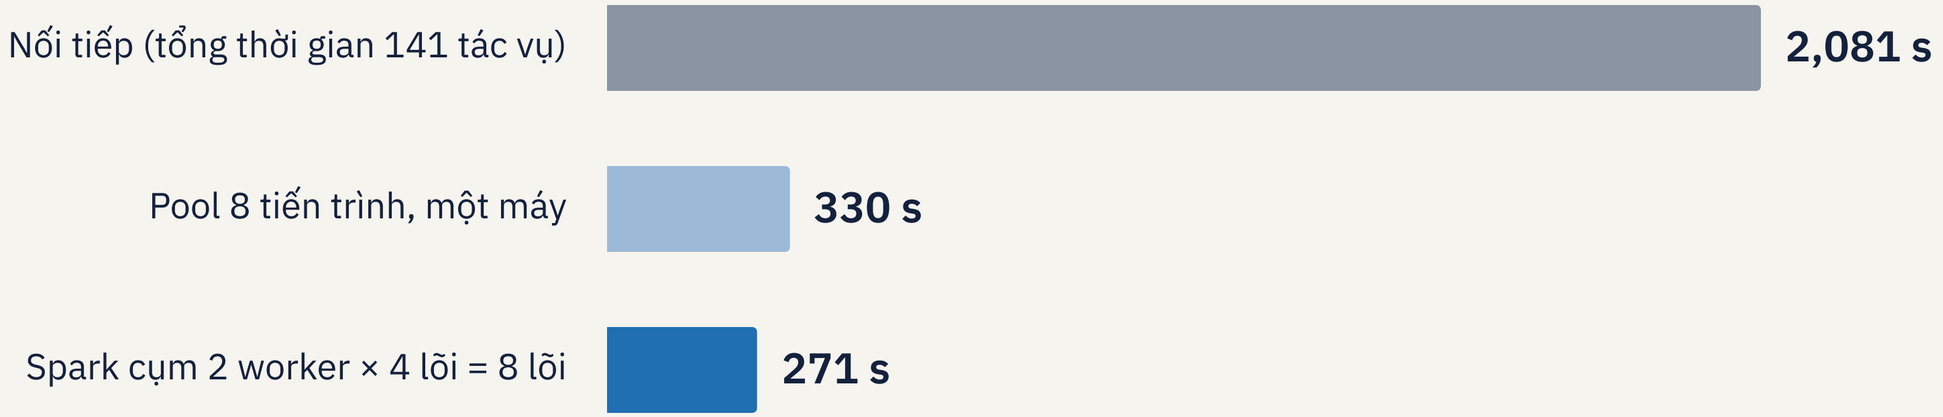
6,246,870 giá trị (54 cột đặc trưng giờ): Spark = Polars từng bit



Polars nhanh hơn Spark 1.8 / 4.7 / 5.0 lần; 2 worker không nhanh hơn 1. Dữ liệu vừa RAM một máy, cụm chạy trên một máy vật lý — Spark chứng minh tính đúng.

Đặng Nguyên Giáp

Spark có lợi thật: walk-forward song song theo tác vụ



7.7×

nhanh hơn nối tiếp trên 8 lõi — mỗi lượt (cấu hình × năm × seed) độc lập, ~15 s CPU

2.3e-13

lệch lớn nhất giữa dự báo trên cụm và local — 141 lượt, 154,494 giá trị

Hệ thống vận hành: bản tin tự động mỗi sáng

05:00 VN
GitHub Actions (cron 20:00 UTC)

→

Tải dữ liệu
GloFAS phát báo + thời tiết dự báo, ~130 ngày gần nhất

→

88 cột
dựng bằng cùng mã với panel lịch sử

→

LightGBM E
đóng băng · 3 seed × 3 horizon · nâng sàn khi hồ xả

→

p_level1
isotonic trên 9,862 ngày OOF · báo khi ≥ 0.091 = 1/11

→

Nhật ký CSV
reports/forecast_log/ · commit · dashboard đọc

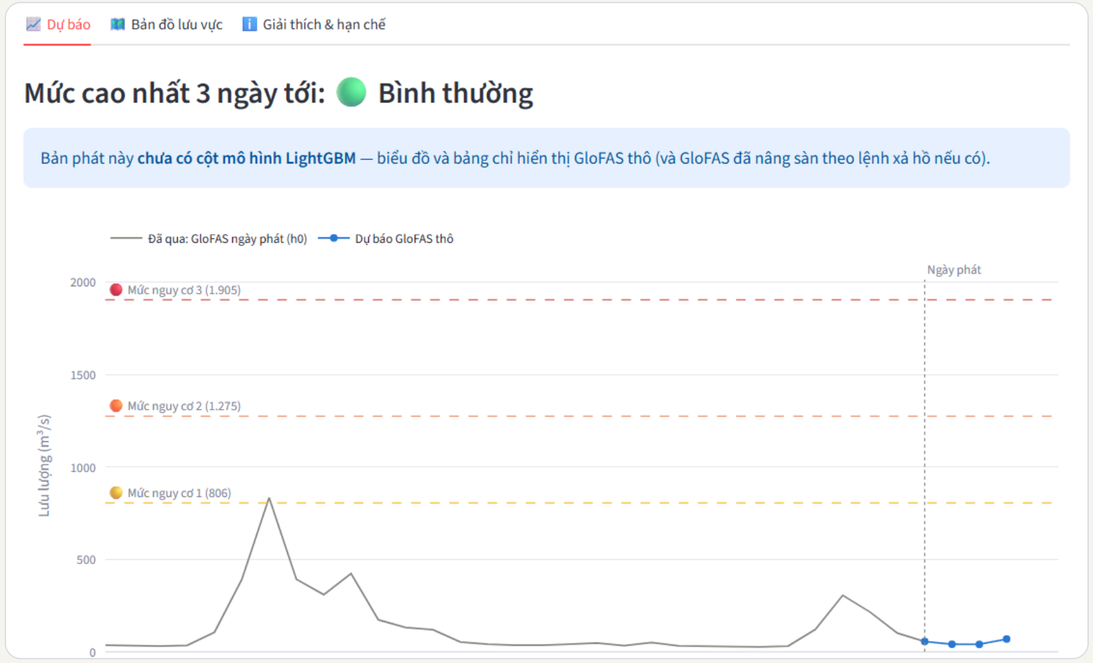
Trạng thái

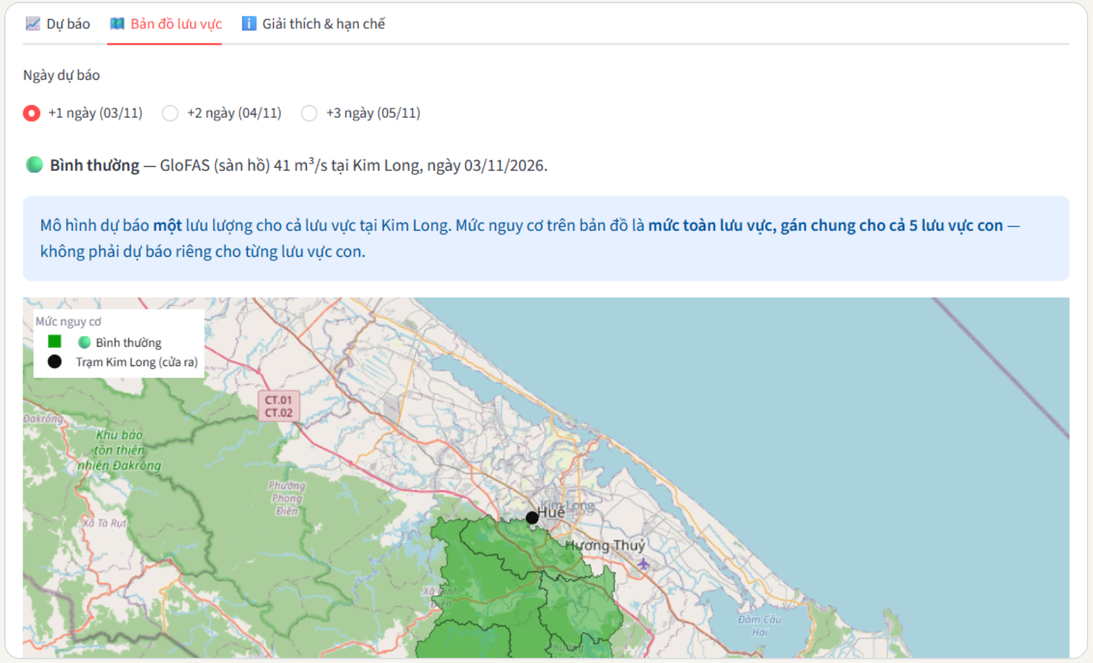
- Nhật ký từ 15/09/2026: 48 ngày phát tới 02/11/2026 (mất 20/09 do lỗi múi giờ, không điền bù)
- Lần chạy đầu có LightGBM trên Actions: **02/11/2026** — h1–h3 47.4 / 65.8 / 63.0 m³/s (GloFAS 41.0 / 40.4 / 69.3)

Đầu vào chạy thật khác lúc học

- Mưa ngày t là mưa **dự báo**, không phải reanalysis
- Độ ẩm đất giữ giá trị cuối; tải bão lỗi = coi như không có bão
- ⇒ NSE báo cáo là **cận trên** của chất lượng chạy thật

Dashboard Streamlit: ba tab





Dự báo

30 ngày qua + 1–3 ngày tới: GloFAS thô, nâng sàn hồ, LightGBM; 3 đường mức nguy cơ; bảng nhãn mức

Bản đồ lưu vực

5 lưu vực con tô theo mức của ngày chọn — một mức chung toàn lưu vực

Giải thích & hạn chế

SHAP theo nhóm, NSE test / walk-forward / persistence, các hạn chế

Streamlit, tự cập nhật khi job commit · ghi rõ: sản phẩm học thuật, không phải bản tin cảnh báo chính thức

Đặc trưng A → E và hàng rào chống rò rỉ

A	Report 2: lưu lượng trễ, mưa ERA5, mùa (66 cột)
B	+ mưa từ 1997: train 4,550 → 9,298 ngày
C	+ độ ẩm đất ERA5-Land (70 cột)
D	+ đại diện mực nước hồ (73 cột)
E	+ bão, không khí lạnh, ENSO (88 cột)

Chống rò rỉ & so sánh công bằng

- **Chia theo thời gian**: train ≤ 2015 · valid → 06/2022 · test ≥ 07/2022 (1,522 ngày)
- **Walk-forward** 13 năm 2013–2025, train mở rộng, gap 3 ngày, ngưỡng mức 1 tính lại từ train từng fold
- **Test rò rỉ** (AC-5): bộ test tự động xanh và NSE < 0.98 — NSE > 0.98 là dấu hiệu nhìn thấy tương lai
- **So sánh có kiểm định**: CI 95 % bootstrap theo fold + Wilcoxon; chênh < 0.01 NSE coi là nhiễu

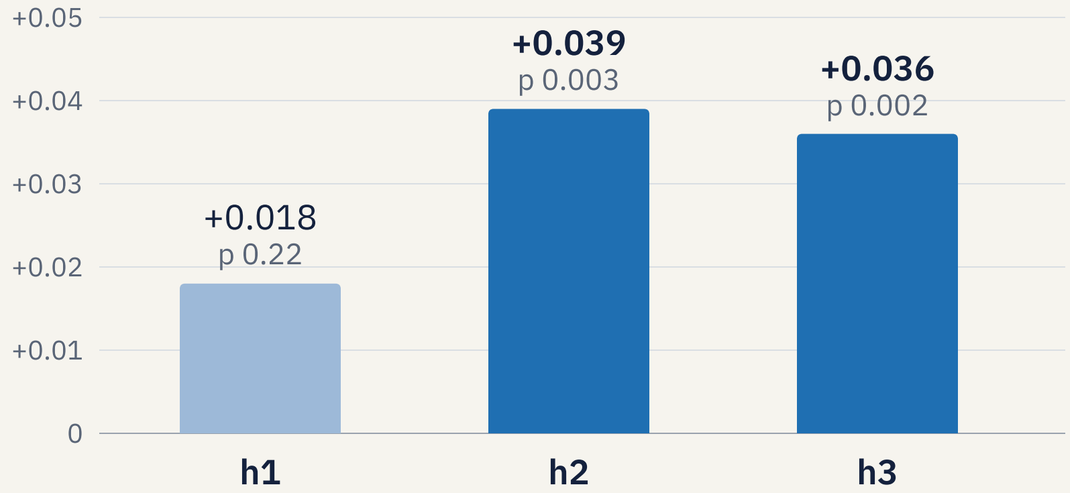
Mọi lựa chọn (cấu hình, hàm mất mát, ngưỡng) chọn bằng valid / walk-forward — không nhìn test.

Mô hình chính: LightGBM cấu hình E

LightGBM cấu hình E

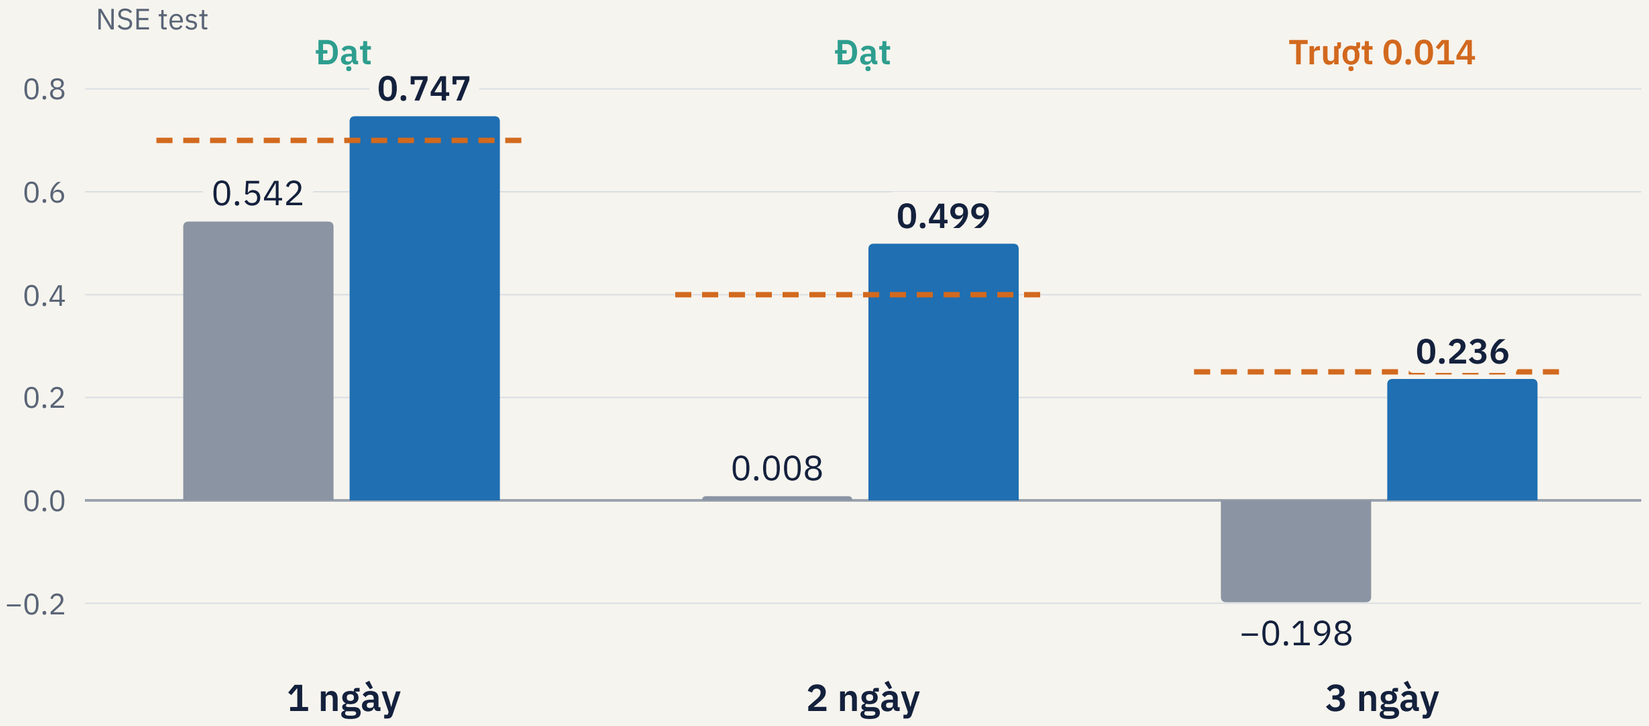
- 88 đặc trưng · một mô hình cho mỗi horizon h1, h2, h3
- 600 cây · learning rate 0.05 · 31 lá · min_child_samples 30
- Trung bình 3 seed
- Hàm mất mát: **L1 ở h1**, **L2 ở h2–h3**
- Đóng băng ngày 02/11/2026

Vì sao L2 ở h2–h3: ΔNSE (L2 – L1), walk-forward 13 năm



Chỉ đổi sang L2 ở horizon có cải thiện ý nghĩa — h1 giữ L1.

So với baseline và tiêu chí AC-1 (test từ 07/2022)



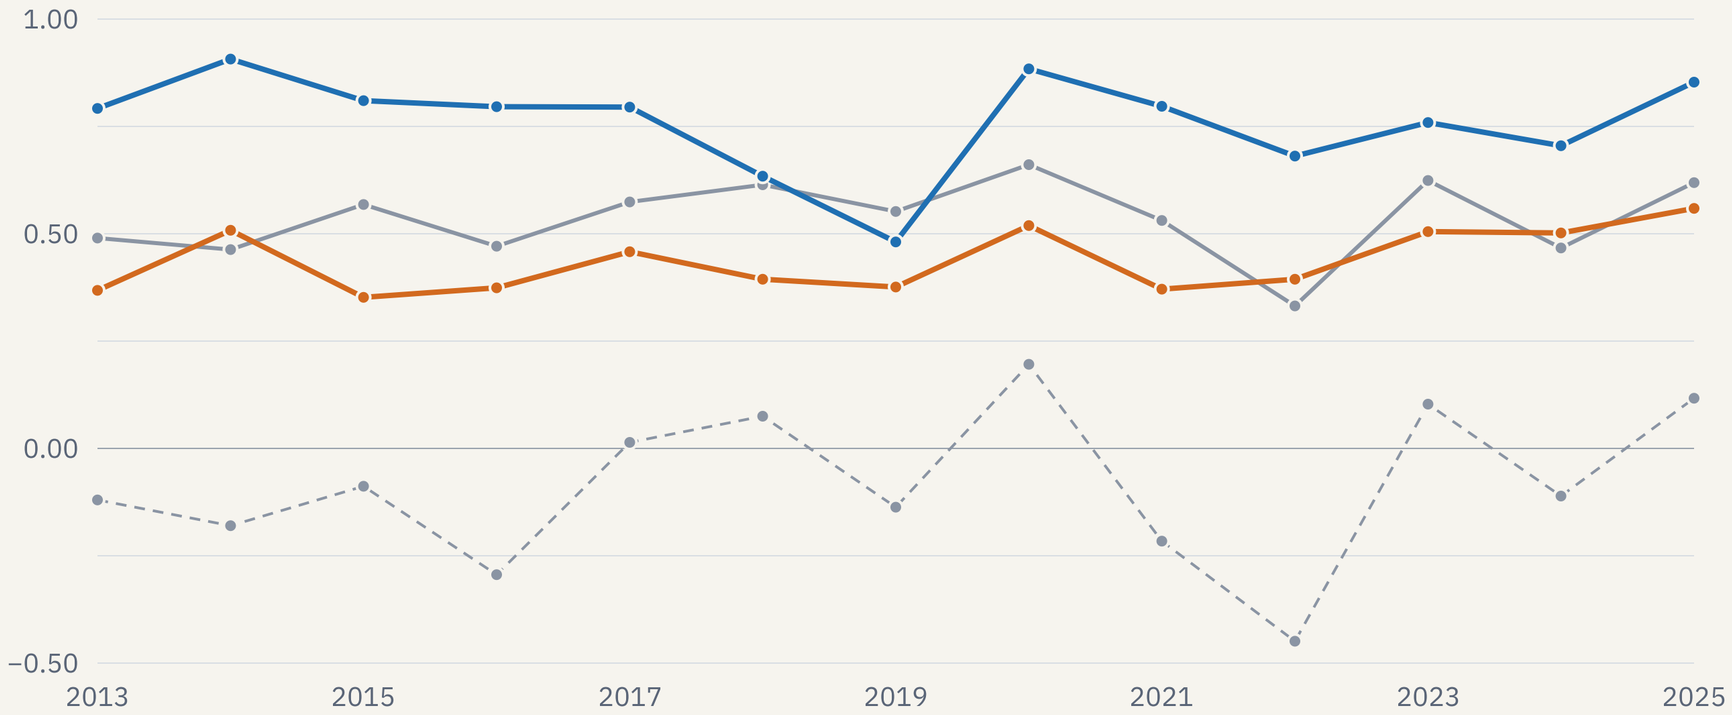
Persistence (Q hôm nay)

LightGBM E

Mục tiêu AC-1: 0.70 / 0.40 / 0.25

h1: RMSE thấp hơn persistence **25.6 %** (AC-1 cần ≥ 20 %). Khí hậu 0.097 · ARIMA −0.093 · seasonal naive −0.434.

Walk-forward 13 năm 2013–2025: kết quả đứng vững



Trung bình 13 năm

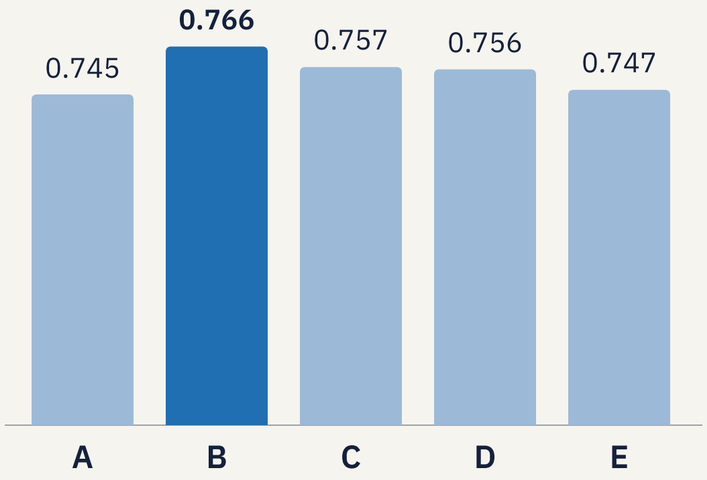
E: 0.761 / 0.437 / 0.206

Persistence: 0.536 / −0.084 / −0.361

E h1 hơn persistence 12/13 năm (trừ 2019); h2, h3 hơn cả 13 năm

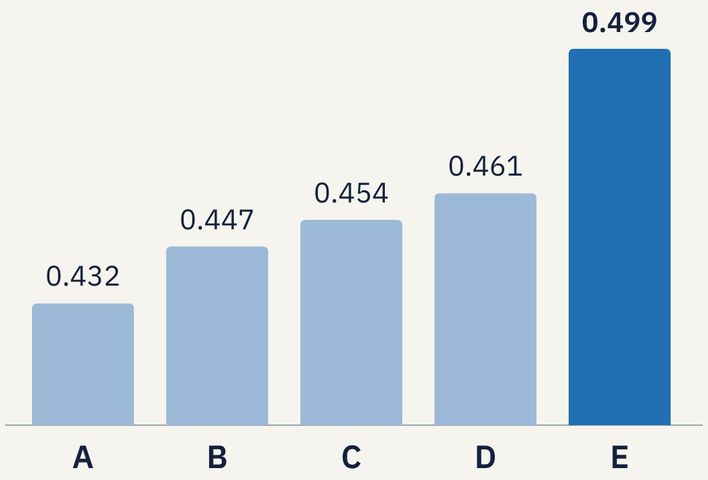
Ablation: nhóm dữ liệu nào giúp horizon nào

h1 · trục từ 0.60



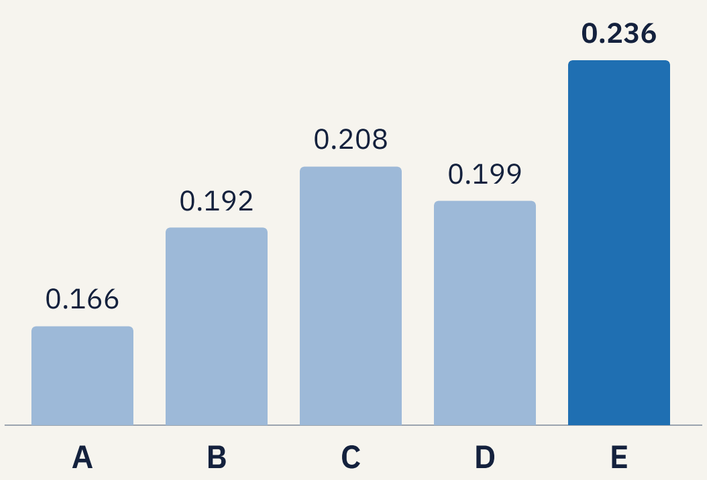
B: +0.021 (mưa từ 1997)

h2 · trục từ 0.40



E: +0.038 so với D

h3 · trục từ 0.14



E: +0.037 so với D

Hệ thống thời tiết báo trước mưa trước khi mưa rơi ⇒ giúp đúng h2–h3. Độ ẩm đất (C), đại diện hồ (D): không thêm gì rõ. Trung bình 3 seed, sd 0.012.

Cảnh báo: ngưỡng theo chi phí + xác suất đã hiệu chỉnh

Mức nguy cơ = phân vị 95 / 98 / 99.5 % lưu lượng mùa lũ = **806 / 1,275 / 1,905 m³/s** — **không** phải BĐ I/II/III (quan hệ H–Q chỉ R^2 0.18 trên 12 đợt, chệch −1.94 m).

Quy tắc báo mức 1 (h1, 13 fold)	Ngưỡng	Bỏ sót	Báo nhầm/năm	Chi phí 10:1
p ≥ 0.5 (mặc định)	0.5	32	3.1	360
Ngưỡng chi phí, xác suất thô	0.03	13	8.4	239
Isotonic + ngưỡng Bayes 1/11	**0.091**	**12**	**8.5**	**230**

Chi phí: một lần bỏ sót = 10 lần báo nhầm. p = 0.5 → ngưỡng chi phí: −34 %, p 0.042.

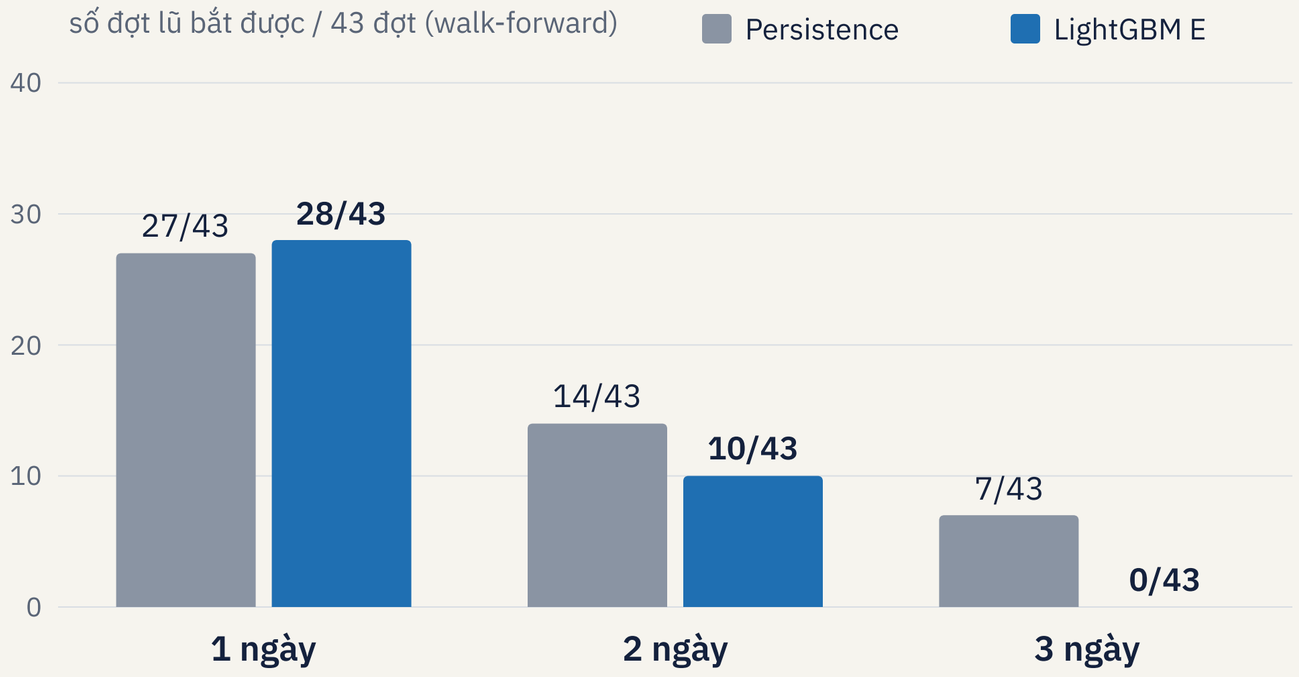
Hiệu chỉnh isotonic

0.0119 → 0.0100

Brier (p 0.027, tốt hơn 9/13 fold) · ECE 0.010 → 0.002

Chi phí không đổi (239 → 230, p 0.75) vì isotonic giữ thứ hạng. Cái được: **xác suất có nghĩa**, ngưỡng tối ưu 0.12 ≈ 1/11 = 0.091 ⇒ job dùng thẳng 1/11.

Theo đợt lũ: h1 bắt ngang persistence nhưng có báo trước



15 đợt

được báo trước ngày lũ bắt đầu — persistence không bao giờ làm được

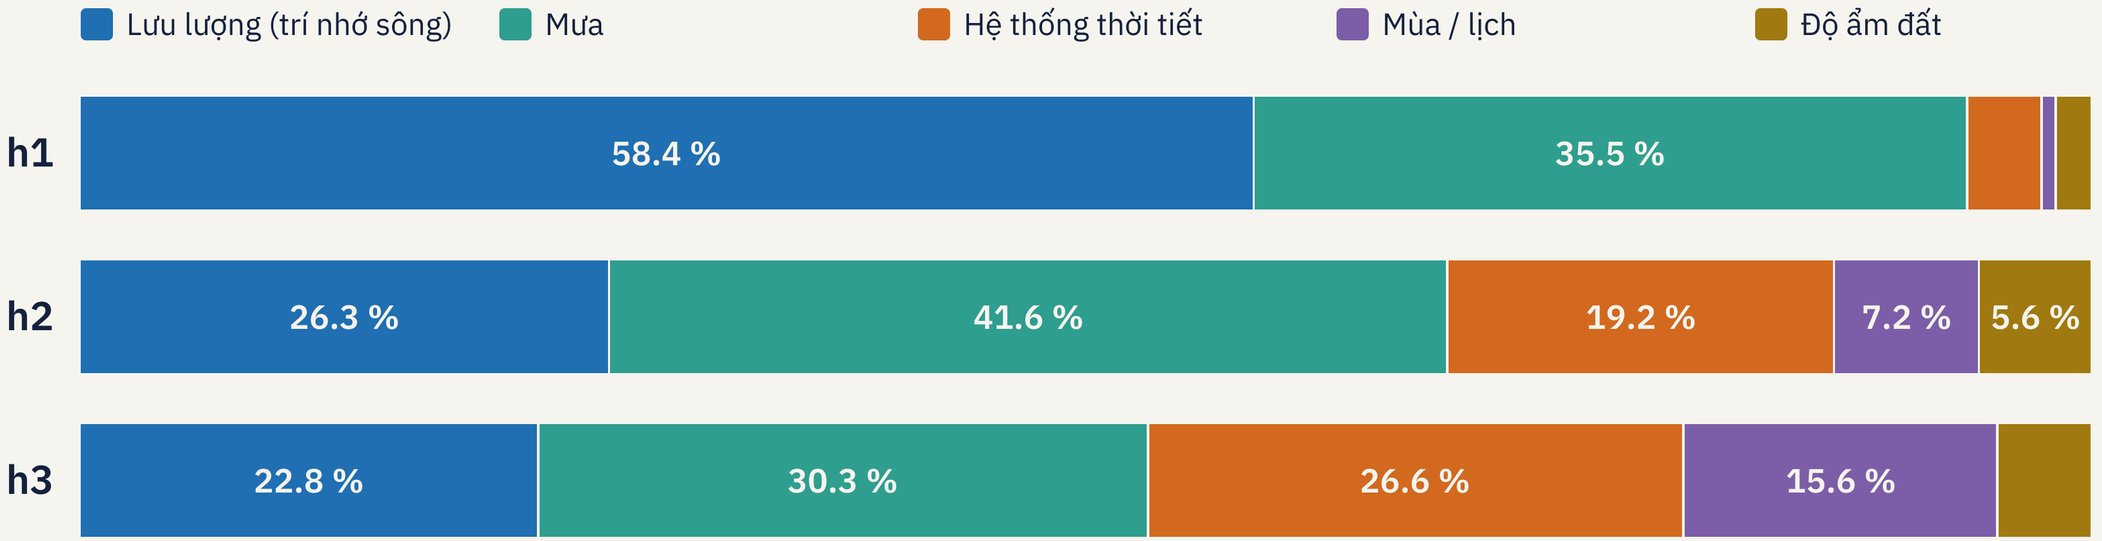
0.80 / 0.54 / 0.31

tỉ số đỉnh dự báo / đỉnh thật (trung vị) — cắt ngọn tăng theo horizon

1 và 0

đợt báo nhầm ở h2, h3 (persistence: 16 và 29)

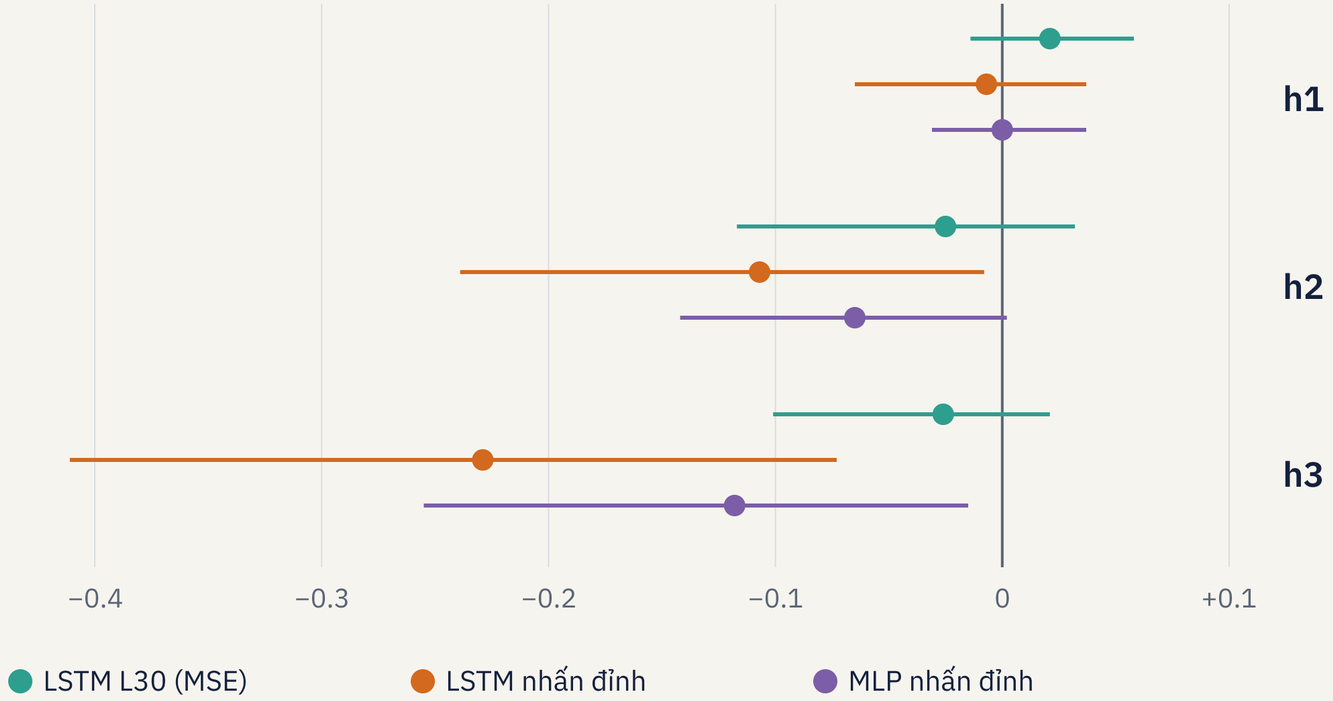
SHAP: mô hình dựa vào đâu



Hợp thuỷ văn: càng xa, trí nhớ sông giảm, thời tiết tăng (khí áp/gió 2.3 → 16.3 %). **Chưa hợp lý, ghi thẳng:** độ ẩm đất tác động **ngược chiều** (trùng thông tin với Q hôm nay); h3 dựa 15.6 % vào lịch. Đỉnh 10/2022: GloFAS 1,967, dự báo 862 — chỉ 12/9,283 ngày train cao như vậy.

Deep learning: không thắng LightGBM một cách vững

ΔNSE so với LightGBM, walk-forward 13 năm (CI 95 % bootstrap theo fold)



Thua rõ ở h3

LSTM nhấn đỉnh −0.229, p 0.033

Kém ổn định

độ lệch giữa seed: DL 0.03–0.20 · LightGBM 0.01

Hơn ở h1 theo sự kiện

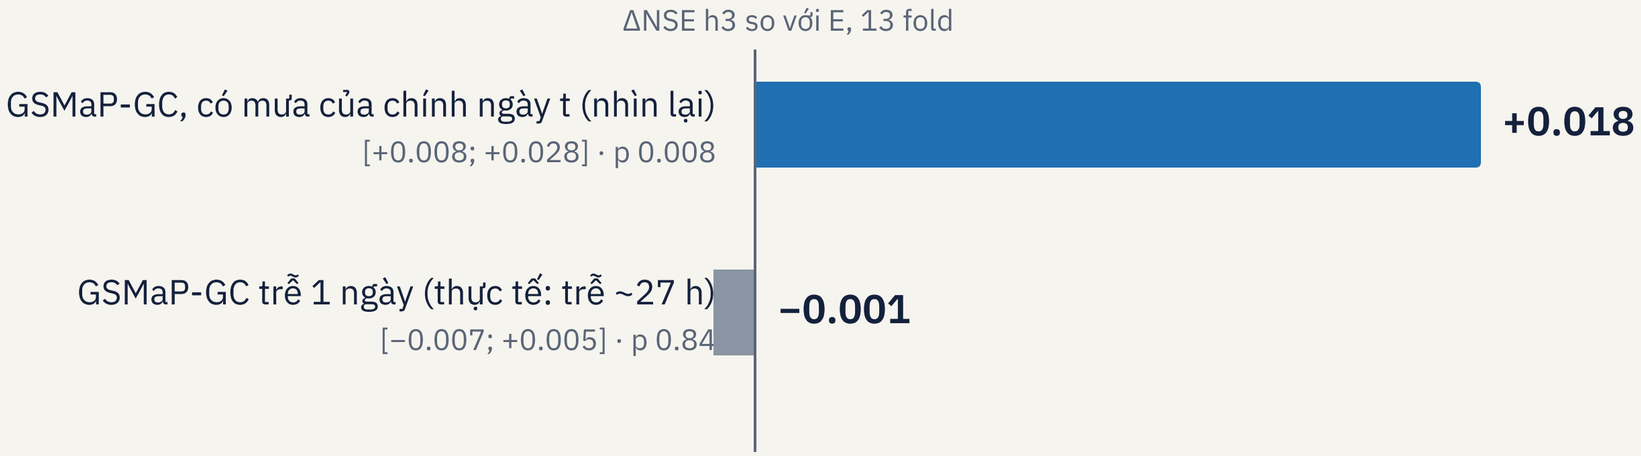
CSI mức 1: DL 0.49 · LightGBM 0.44

Phân tán không giúp

DDP 2 rank cùng NSE, chậm hơn 1 tiến trình · MLlib trên dữ liệu đầy đủ, 13 fold: kém E cả 3 horizon (h1 −0.044 / −0.049, $p < 0.05$)

Mai Thị Lệ Huyền

Mưa vệ tinh: có ích khi nhìn lại, mất khi chạy thật



GSMaP_NRT (trễ ~4.7 h, sản phẩm khác, học lại bằng lịch sử NRT): giúp mô hình yếu A (+0.009 / +0.019 / +0.012, p ≤ 0.008) nhưng **không giúp E** (−0.002 / +0.003 / −0.001).

⇒ **Không đưa mưa vệ tinh vào job hằng ngày. Bài học: một lần chia đánh giá IMERG cao hơn walk-forward (+0.017 → +0.013).**

Mai Thị Lệ Huyền

Thử giảm cắt ngọn lũ: ba hướng, tiêu chí đặt trước

Tiêu chí đặt TRƯỚC khi chạy: ΔNSE h2/h3 > 0 với Wilcoxon p < 0.05 **và** h1 không giảm quá 0.01 (hoặc bắt đỉnh rõ hơn mà NSE không giảm quá 0.01). Mốc E tái lập: 0.761 / 0.437 / 0.206.

Biến thể (so với E, 13 fold)	h1 ΔNSE	h2 ΔNSE	h3 ΔNSE	Kết luận
B1 · trọng số mẫu nhấn đỉnh α = 3	+0.011 (p 0.13)	+0.012 (p 0.22)	+0.001	Không ý nghĩa; α chọn sau khi xem
B2 · hiệu chỉnh isotonic sau dự báo	−0.040	−0.008	**−0.027 (p 0.001)**	Làm hại: thua 12/13 fold ở h3
B3 · ghép 50/50 E + LSTM	**+0.029 (p 0.048)**	−0.022	**−0.023 (p 0.021)**	Giúp h1, hại h2–h3

Không biến thể nào đạt ⇒ giữ E, đóng băng 02/11/2026. Cắt ngọn ở h2–h3 là do thiếu thông tin (mưa gây lũ chưa rơi), không chữa được bằng hàm mất mát hay hậu xử lý.

Mai Thị Lệ Huyền

Hạn chế — nói thẳng

Mục tiêu là mô phỏng

Học lưu lượng GloFAS, không phải số đo trạm; GloFAS không có hồ và thiếu lũ lớn

h3 dưới AC-1

Test 0.236, walk-forward 0.206 — dưới 0.25; đỉnh lũ bị cắt ở mọi horizon

GloFAS đổi chế độ 07/2022

Chỉ 3 năm sau đổi (2023–2025: 0.772 / 0.522 / 0.223) — chưa kiểm định riêng được

Một ô, mục tiêu ngày

Ô 5 km không tách sông Bồ; bản đồ chỉ có một mức chung toàn lưu vực

Sự kiện hiếm

Chỉ mức 1 đủ dữ liệu; mức 2, mức 3 và AC-2 chưa đánh giá được

Chưa so với GloFAS thô (AC-3)

Kho dự báo quá khứ không truy cập được; nhật ký mới từ 15/09/2026; đầu vào chạy thật là mưa dự báo

Hướng tiếp theo

Ghép E + LSTM theo horizon ở h1

Kiểm trên mùa lũ mới, đúng tiêu chí đặt trước

Mưa dự báo tốt hơn + số liệu xả hồ

Chỗ duy nhất có thể gỡ cắt ngọn ở h2–h3

Tích luỹ nhật ký → kiểm AC-3

So LightGBM với GloFAS thô trên các ngày đã có giá trị kiểm

GloFAS v5 có hồ chứa

Chạy lại phép thử hồ, huấn luyện lại khi nguồn chuyển sang v5

Walk-forward trên nhiều máy thật

Spark song song theo tác vụ khi dữ liệu / số mô hình vượt một máy

Xin số liệu trạm KTTV

Nếu đồ án tiếp tục sau môn học: mực nước giờ Kim Long

Kết luận: ba điều cần nhớ

1

Hữu ích 1–2 ngày

Test 0.747 / 0.499, walk-forward 0.761 / 0.437 — vượt persistence; h3 0.236 trượt AC-1 0.014

2

Cảnh báo có cơ sở

Ngưỡng chi phí −34 % chi phí; xác suất hiệu chỉnh Brier 0.0119 → 0.0100; báo ở 1/11

3

Chạy thật, trung thực

Job mỗi sáng + dashboard; Spark trùng từng bit; kết quả âm (DL, vệ tinh, cắt ngọn) ghi kèm bằng chứng

RQ1 dự báo được lưu lượng: có ở 1–2 ngày, một phần ở 3 ngày. **RQ2** không theo cấp BĐ chính thức; theo mức 1: POD 0.88, FAR 0.54 (quy tắc chi phí, 13 fold). **RQ3** gián tiếp: SHAP h1 mưa thượng nguồn 11.2 % so với mưa toàn lưu vực 9.5 %.

Cảm ơn thầy cô đã lắng nghe

h1 0.747 · h2 0.499 · h3 0.236 (trượt 0.014) · 13 năm walk-forward · chạy mỗi sáng

Nhóm xin nhận câu hỏi — các câu hay gặp:

Sao không so với GloFAS thô?

Kho dự báo quá khứ không truy cập được; nhật ký mới từ 15/09/2026

Sao không dùng BĐ I/II/III?

H–Q R^2 0.18 ⇒ dùng mức nguy cơ tương đối

Spark chậm hơn thì để làm gì?

Chứng minh đúng khi phân tán; có lợi khi song song tác vụ (7.7×)

E + LSTM tốt ở h1 sao không dùng?

Tiêu chí đặt cho h2–h3; chọn sau khi xem; thêm PyTorch vào job